

**CM106 - Otimização I**  
12 de Abril de 2018 - Prova 1

**Gabarito**

1. 15 Considere a função  $f(x, y, z) = x^3 - 3x + y^3 - 12y + z^3 - 27z$ . Calcule seus pontos críticos e classifique-os.

**Solution:** O gradiente de  $f$  é  $\nabla f(x, y, z) = \langle 3x^2 - 3, 3y^2 - 12, 3z^2 - 27 \rangle$ . Os 8 pontos críticos são  $(\pm 1, \pm 2, \pm 3)$ .

A Hessiana é  $\nabla^2 f(x, y, z) = \text{diag}(6x, 6y, 6z)$ , então os autovalores são  $6x$ ,  $6y$  e  $6z$ . Sendo assim, a Hessiana só é definida positiva se  $x, y, z$  são positivos, e análogo para negativa. Logo  $(1, 2, 3)$  é minimizador local,  $(-1, -2, -3)$  é maximizador local e os outros 6 pontos são pontos de sela.

2. Faça o que se pede:

- (a) 20 A partir de  $x^{(0)} = (2, 1)$  para  $f(x) = x_1^2 + 2x_2^2$ , calcule  $x^{(1)}$  usando o Método do Gradiente com busca por *backtracking* com parâmetro 0.5, e satisfazendo a condição de Armijo com parâmetro 0.5.

**Solution:**  $f(x^{(0)}) = 6$ .  $\nabla f(x) = (2x_1, 4x_2)^T$ .  $\nabla f(x^{(0)}) = (4, 4)^T$ .  $d_0 = (-4, -4)^T$ .  $\nabla f(x^{(0)})^T d_0 = -32$ .

$$t = 1$$

$$f(2 - 4, 1 - 4) = f(-2, -3) = 22 > 6$$

$$t = 1/2$$

$$f(2 - 2, 1 - 2) = f(0, -1) = 2$$

$$f(2, 1) - 1/2 \times 1/2 \times 32 = 6 - 8 = -2 < 2$$

$$t = 1/4$$

$$f(2 - 1, 1 - 1) = f(1, 0) = 1$$

$$f(2, 1) - 1/4 \times 1/2 \times 32 = 6 - 4 = 2 > 1$$

$$x^{(1)} = x^{(0)} + \frac{1}{4}d_0 = (1, 0)^T.$$

- (b) 10 O Método SR1 para aproximar a Hessiana da função  $f$  é dado pela atualização

$$B_{k+1} = B_k + \frac{v_k v_k^T}{v_k^T s_k},$$

onde  $v_k = y_k - B_k s_k$ ,  $s_k = x^{(k+1)} - x^{(k)}$ , e  $y = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$ . Considerando  $B_0 = I$ , calcule  $B_1$ , usando  $x^{(0)}$  e  $x^{(1)}$  do passo anterior.

**Solution:**  $s_0 = (1, 0)^T - (2, 1)^T = (-1, -1)^T$ .  $y_0 = \nabla f(1, 0) - \nabla f(2, 1) = (2, 0)^T - (4, 4)^T = (-2, -4)^T$ .

$$v_0 = \begin{bmatrix} -2 \\ -4 \end{bmatrix} - I \begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ -3 \end{bmatrix}. v_0^T s_0 = (-1, -3)(-1, -1)^T = 4.$$

$$B_1 = I + \frac{1}{4} \begin{bmatrix} -1 \\ -3 \end{bmatrix} \begin{bmatrix} -1 & -3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \frac{1}{4} \begin{bmatrix} 1 & 3 \\ 3 & 9 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 5 & 3 \\ 3 & 13 \end{bmatrix}.$$

3. 15 O problema de Quadrados Mínimos Regularizado consiste de minimizar a função

$$f(x) = \frac{1}{2} \|Ax - b\|^2 + \frac{\lambda}{2} \|x\|^2,$$

onde  $A \in \mathbb{R}^{m \times n}$ , com  $m > n$ ,  $b \in \mathbb{R}^m$ ,  $x \in \mathbb{R}^n$  e  $\lambda \geq 0$  é um parâmetro de regularização. Mostre que esse problema sempre tem minimizador global único para  $\lambda > 0$ , e descreva esse minimizador.

**Solution:**

$$\nabla f(x) = A^T(Ax - b) + \lambda x = (A^T A + \lambda I)x - A^T b.$$

$$\nabla^2 f(x) = A^T A + \lambda I.$$

A matriz  $A^T A + \lambda I$  é definida positiva se  $\lambda > 0$ :

$$y^T (A^T A + \lambda I) y = \|Ay\|^2 + \lambda \|y\|^2 > 0, \forall y \neq 0.$$

Logo, ela é inversível, e o sistema  $\nabla f(x) = 0$  terá solução. Como é definida positiva,  $\nabla^2 f(x)$  é definida positiva, e essa solução é minimizador local. Como  $\nabla^2 f(x)$  é definida positiva para todo  $x$ , então  $f$  é convexa, e seu minimizador local é global.

4. Faça o que se pede:

- (a) 10 Mostre que a função  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  dada por  $f(x) = \sum_{i=1}^n |x_i|$  é convexa, mas que a função  $g: \mathbb{R}^2 \rightarrow \mathbb{R}$  dada por  $g(x, y) = |xy|$  não é convexa.

**Solution:** Sejam  $x, y \in \mathbb{R}^n$ . Daí,

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= \sum_{i=1}^n |\lambda x_i + (1 - \lambda)y_i| \leq \sum_{i=1}^n \lambda |x_i| + (1 - \lambda) |y_i| \\ &= \lambda \sum_{i=1}^n |x_i| + (1 - \lambda) \sum_{i=1}^n |y_i| = \lambda f(x) + (1 - \lambda)f(y). \end{aligned}$$

Por outro lado,  $g(3, 1) = g(1, 3) = |3| = 3$ , mas  $g(2, 2) = |2 \times 2| = 4$ .  $(2, 2) = \frac{1}{2}((3, 1) + (1, 3))$ , mas  $g(2, 2) > \frac{1}{2}(f(3, 1) + f(1, 3))$ .

- (b) **10** Mostre que se  $\{x^{(k)}\}$  é uma sequência gerada pelo Método do Gradiente com Busca Exata, então  $\nabla f(x^{(k)})$  é ortogonal à  $\nabla f(x^{(k+1)})$ .

**Solution:**  $x^{(k+1)} = x^{(k)} + t_k d_k$ , onde  $d_k = -\nabla f(x^{(k)})$  e  $t_k = \arg \min_t f(x^{(k)} + t d_k)$ .

Seja  $\varphi(t) = f(x^{(k)} + t d_k)$ . Logo,  $\varphi'(t_k) = 0$ . Mas,

$$\varphi'(t) = d_k^T \nabla f(x^{(k)} + t d_k),$$

de modo que

$$0 = \varphi'(t_k) = d_k^T \nabla f(x^{(k+1)}) = -\nabla f(x^{(k)})^T \nabla f(x^{(k+1)}).$$

- (c) **10** Considere  $f(x) = (x_1 - 1)^2 x_2$ , e  $\bar{x} = (1, 0)$ . Mostre que  $\bar{x}$  é um ponto crítico e descubra se é minimizador, maximizador ou ponto de sela, utilizando características da função.

**Solution:** Temos  $\nabla f(x) = \begin{bmatrix} 2(x_1 - 1)x_2 \\ (x_1 - 1)^2 \end{bmatrix}$ , logo  $\nabla f(1, 0) = 0$ , ou seja  $\bar{x}$  é ponto crítico.

Temos  $\nabla^2 f(x) = \begin{bmatrix} 2x_2 & 2(x_1 - 1) \\ 2(x_1 - 1) & 0 \end{bmatrix}$ , logo  $\nabla^2 f(0) = 0$ , que não ajuda nada.

Por outro lado,  $f(1 + t, t) = t^3$ , que para  $t > 0$  é positivo, e para  $t < 0$  é negativo. Como  $f(1, 0) = 0$ , então  $(1, 0)$  é ponto de sela.

- (d) **10** Prove ou dê um contra-exemplo: “Se  $\bar{x}$  é minimizador local, mas  $\nabla^2 f(\bar{x})$  não é definida positiva, então o Método de Newton Puro nunca converge para  $\bar{x}$ , a partir de qualquer  $x^{(0)} \neq \bar{x}$ .”

**Solution:** A afirmação é falsa. Considere  $f(x) = \sum_{i=1}^n x_i^4$ . Temos  $\nabla f(x) = 4(x_1^3, \dots, x_n^3)^T$  e  $\nabla^2 f(x) = \text{diag}(12x_1^2, \dots, 12x_n^2)$ . A iteração de Newton vira

$$x_i^+ = x_i - \frac{4x_i^3}{12x_i^2} = \frac{2}{3}x_i,$$

ou seja  $x^{(k+1)} = \frac{2}{3}x^{(k)} \rightarrow 0$ , que é o minimizador local de  $f$ . Note que a velocidade de convergência é linear, que é o problema gerado por não ser definida positiva.

5. **(Bônus)** Seja  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função diferenciável até segunda ordem. Um método de otimização para encontrar um minimizador de  $f$  é o seguinte:

1. Dado  $x^{(0)} \in \mathbb{R}^n$ ,  $\sigma_0 > 0$ , faça  $k = 0$ ;

2. Defina

$$m_k(d) = \frac{1}{2}d^T B_k d + d^T g_k + \frac{\sigma_k}{3} \|d\|^3,$$

onde  $B_k = \nabla^2 f(x^{(k)})$  e  $g_k = \nabla f(x^{(k)})$ ;

3. Encontre  $d_k$  minimizador de  $m_k$ ;
4. Se houve decréscimo suficiente, faça  $x^{(k+1)} = x^{(k)} + d^{(k)}$  e escolha  $\sigma_{k+1} \leq \sigma_k$ ;
5. Senão, faça  $x^{(k+1)} = x^{(k)}$  e escolha  $\sigma_{k+1} > \sigma_k$ .
6. Incremente  $k$  e volte ao passo 2.

Faça o que se pede:

- (a) **10** A parte difícil do método é encontrar o minimizador de  $m_k$ . Ao invés, podemos buscar um minimizador para  $\varphi(t) = m_k(-tg_k)$ , com  $t > 0$ . Mostre que  $-g_k$  é uma direção de descida para  $m_k$  no ponto  $d = 0$ .

**Solution:** Podemos calcular  $\nabla m_k$ . Veja que  $\|d\|^3$  não é simplesmente cair a potência, pois  $\|d\|^3 = (d^T d)^{3/2}$ .

$$\nabla m_k(d) = B_k d + g_k + \frac{\sigma_k}{3} \frac{3}{2} (d^T d)^{1/2} 2d = B_k d + g_k + \sigma_k \|d\| d.$$

Daí,

$$\nabla m_k(0) = g_k,$$

e  $-g_k$  é obviamente direção de descida.

A outra maneira de fazer isso é olhar para  $m_k(-tg_k)$ :

$$m_k(-tg_k) = \frac{t^2}{2} g_k^T B_k g_k - t g_k^T g_k + \frac{\sigma_k t^3}{3} \|g_k\|^3.$$

Daí,  $\frac{m_k(-tg_k) - m_k(0)}{t} \rightarrow -\|g_k\|^2 < 0$ .

- (b) **10** Prove que  $m_k$  sempre tem um minimizador para  $\sigma_k > 0$ .

**Solution:** Uma maneira de mostrar isso é ver que  $m_k(d) \rightarrow \infty$  quando  $\|d\| \rightarrow \infty$ . Logo, dado  $M > 0$  suficientemente grande, o conjunto  $L = \{d \in \mathbb{R}^n \mid m_k(d) \leq M\}$  é não vazio e limitado. Note que  $L$  é fechado, logo é compacto, e portanto vale o Teorema de Weierstrass do valor extremo: existe um minimizador de  $m_k$  em  $L$ . O aluno pode usar coercividade para provar diretamente.